

Le poids de la vérifiabilité dans le jugement des LLMs - Une étude épistémique sur l'évaluation de l'information

Auteur : BENHARRATS Guillaume

Date : 25 septembre 2026

Résumé

Nous explorons comment un petit LLM local (DeepSeek-R1-Distill-Qwen-1.5B) auto-évalue la vérifiabilité et la plausibilité d'énoncés politiques, et testons comment ces évaluations internes sont associées à sa propre croyance finale. Sur 260 items LIAR2 échantillonnés (258 analysés), le modèle se réfugie massivement dans la neutralité (note de 4/7 donnée dans 56 % des cas en vérifiabilité et 42 % en croyance). Il distingue à peine le vrai du faux factuel ($AUC = 0,57$, un score proche du hasard). Enfin, si la vérifiabilité et la croyance semblent d'abord liées (corrélation brute $\rho = 0,30$), le poids spécifique de la vérifiabilité chute fortement (β passant de 0,43 à 0,17) dès que la plausibilité ($\beta = 0,589$) est prise en compte dans le modèle, rendant son effet statistiquement incertain. Il s'agit d'une étude exploratoire, non causale, sans lien établi avec la cognition humaine. Elle présente de nombreuses limites méthodologiques.

1 Introduction

À l'approche des prochaines élections présidentielles de 2027, la question de la désinformation et de la vérification des faits (fact-checking) prend une place particulière, notamment avec l'omniprésence croissante des LLM. Bien que ce projet s'appuie sur le corpus politique américain LIAR2 faute d'équivalent francophone structuré, les enjeux liés à ces modèles restent universels. Utilisés massivement par un public en proie au doute pour trier le flux d'informations et valider des déclarations politiques, ces outils posent une question cruciale : s'avèrent-ils de robustes remparts contre la manipulation, ou constituent-ils eux-mêmes un danger potentiel en raison de biais internes et d'une incapacité à évaluer rigoureusement la vérité ?

Ce projet se situe à la croisée des sciences cognitives et de la recherche sur la désinformation, s'appuyant sur le cadre théorique de la vigilance épistémique. Loin d'être crédules, les humains filtrent l'information communiquée en évaluant principalement des critères comme la plausibilité du contenu (sa cohérence avec leurs connaissances) et la fiabilité de la source. Concernant la vérifiabilité, les gens réfléchissent à deux fois avant de mentir, car ils savent que si leurs affirmations sont trop faciles à vérifier, ils risquent d'être démasqués et de perdre la face. Dès lors, la question se pose de savoir si un modèle de langage intègre de telles dimensions logiques ou s'il se laisse simplement piéger par la cohérence sémantique et textuelle des énoncés.

L'objectif de ce projet pilote est double : observer comment le modèle auto-évalue la vérifiabilité et la plausibilité, et estimer comment ces notes internes sont associées à sa propre croyance face à des énoncés politiques. Il s'agit d'une démarche exploratoire et

corrélacionnelle préparant le terrain pour des expérimentations plus poussées. Ce questionnement est d’autant plus fondamental que l’utilisation aveugle de LLM par des citoyens en quête de certitudes politiques pourrait amplifier, plutôt que réduire, la propagation de fausses croyances.

2 Données et méthode

- **Données** : Nous avons extrait aléatoirement 2000 affirmations du jeu de test LIAR2. La vérité terrain a été explicitement binarisée : les labels 3 (*Half-true*), 4 (*Mostly-true*) et 5 (*True*) ont été regroupés sous la valeur 1 (Vrai), le reste sous 0 (Faux). Ce sous-échantillonnage de 260 items parmi les 2000 a été réalisé afin de respecter une contrainte budgétaire limitant le temps d’inférence à environ 60 minutes. Les variables de crédibilité de la source et de congruence politique sont absentes de ce pilote.
- **Modèle** : L’inférence a été réalisée localement sur `deepseek-ai/DeepSeek-R1-Distill-Qwen-1.5B`, en précision `float16` via l’accélération Apple Silicon (MPS).
- **Paramètres** : Température = 0.6, `top_p` = 0.95, `max_new_tokens` = 4096, `seed` = 42, une génération par item.
- **Protocole** : Le prompt demandait d’évaluer la vérifiabilité (V), la plausibilité (P) et la croyance (C) de 1 à 7. Les 6 permutations de l’ordre des questions ont été équilibrées (42 à 44 items par ordre). 6 items de contrôle ont été ajoutés à la file d’attente. Il est à noter que le prompt d’évaluation était rédigé en français, tandis que les énoncés de la base LIAR2 soumis au modèle étaient en anglais, ce qui constitue une limite assumée.
- **Extraction** : Sur 266 requêtes générées au total, 3 ont échoué en raison d’erreurs d’extraction JSON. Concrètement, sur les 260 items LIAR2 échantillonnés, 2 ont été exclus (troncature par limite de tokens et clés hallucinées) ; sur les 6 items de contrôle, 1 a échoué (erreur de type float). Nous avons donc analysé un total exact de 263 items exploitables (258 LIAR2 et 5 contrôles).

3 Résultats

S’agissant d’une étude pilote exploratoire, les hypothèses n’ont pas fait l’objet d’un pré-enregistrement. Par ailleurs, plusieurs analyses statistiques ayant été menées sans correction stricte pour les comparaisons multiples, les tests et intervalles de confiance rapportés ci-dessous doivent être interprétés à titre descriptif.

3.1 Distribution des notes

Le modèle exprime une forte incertitude (voir Figure 1). Il se replie d’ailleurs davantage sur la neutralité pour évaluer la vérifiabilité (56 % de « 4 ») que pour évaluer la croyance finale (42 % de « 4 »). Au total, 15 % des réponses sont des triplets purement neutres (4,4,4).




FIGURE 1 – Distribution des notes de croyance (à gauche) et de vérifiabilité (à droite) sur l'échelle 1-7.

3.2 Discrimination Vrai/Faux

La capacité du modèle à classer correctement une affirmation vraie par rapport à une fausse est très faible :

- **Tous les items (analyse principale)** : AUC = 0,57 (IC95 [0,50 ; 0,63]). La corrélation de Spearman entre le label d'origine (0-5) et la croyance est modeste ($\rho = 0,15$).
- **Sans les *Half-True* (sensibilité)** : L'exclusion des énoncés ambigus fait très légèrement monter l'AUC à 0,59 (IC95 [0,52 ; 0,67]).

3.3 Items de contrôle

L'évaluation des items de contrôle met en lumière des limites critiques quant à la validité de l'échelle (voir Tableau 1) :

Contrôle	Vérifiabilité	Plausibilité	Croyance
Eau à 100 °C (vrai)	4	4	4
Paris capitale (vrai)	5	5	7
Soleil autour de la Terre (faux)	4	4	4
Voisin, 3 pensées (invérifiable)	4	7	4
Berger et chèvre (invérifiable)	3	4	4

TABLE 1 – Évaluation des items de contrôle

Sur trois contrôles vrai/faux exploitables, un seul (Paris capitale) produit une croyance élevée (7). Le contrôle faux trivial (« Le Soleil tourne autour de la Terre ») obtient une croyance neutre (4), ce qui indique que le modèle ne rejette pas une affirmation fausse et manifestement vérifiable par un enfant de 10 ans. La validité de l'échelle de croyance est donc fortement questionable.

3.4 Corrélations et Modélisation Ordinale

Prises isolément (voir Figure 2), les dimensions sont associées : $\rho_{V,C} = 0,30$, $\rho_{P,C} = 0,51$, et $\rho_{V,P} = 0,39$.




FIGURE 2 – Diagramme à bulles Vérifiabilité $\times$ Croyance avec droite de régression.

L'ajustement de modèles logit ordinaux permet d'estimer l'apport spécifique de la vérifiabilité (voir Figure 3) :

- **Modèle A (Vérifiabilité seule)** : $\beta_V = 0,427$ (Bootstrap par sujet IC95 [0,26 ; 0,59]).
- **Modèle B (Vérifiabilité + Plausibilité)** : $\beta_V = 0,166$ (Bootstrap par sujet IC95 [-0,03 ; 0,37]) ; $\beta_P = 0,589$.
- **Robustesse** : L'intégration de l'ordre de présentation comme covariable laisse le coefficient de la vérifiabilité inchangé à 0,184 (IC95 [0,00 ; 0,36]).

L'association vérifiabilité-croyance diminue nettement lorsque la plausibilité est ajoutée, avec un intervalle de confiance frôlant zéro.




FIGURE 3 – Forest plot des coefficients β avec intervalles de confiance à 95 % pour les Modèles A et B.

4 Discussion

Ce pilote démontre la **faisabilité technique** de l'utilisation d'un petit LLM pour l'annotation épistémique : le pipeline d'extraction est robuste et reproductible.

En revanche, la **validité conceptuelle** des mesures n'est pas démontrée. Le comportement sur les contrôles triviaux suggère que l'échelle est mal calibrée pour ce modèle.

La baisse du coefficient de la vérifiabilité dans le Modèle B ne permet pas d'exclure un effet indépendant, mais elle ne le soutient pas fermement. Plus important encore : la plausibilité et la croyance étant générées simultanément dans le même texte, la plausibilité agit comme un mauvais contrôle statistique. Elle absorbe inévitablement la variance d'une variable latente commune liée à la cohérence sémantique interne du modèle. L'inférence causale est impossible sous ce design.

5 Conclusion et Perspectives

Ce pilote identifie trois obstacles méthodologiques concrets :

1. La nécessité d'évaluer les dimensions via des **générations séparées** (un prompt exclusif par dimension) pour briser la colinéarité de génération.
2. L'impératif de calibrer l'échelle de croyance sur des contrôles triviaux stricts avant toute annotation massive.
3. Le besoin d'une validation du codage LLM contre des annotateurs humains avec une mesure d'accord rigoureuse (au-delà du hasard).

Ces ajustements permettront de tester expérimentalement si l'asymétrie accusation/dénégation s'observe dans le jugement artificiel.

Annexe : Formalisation Statistique

A. Modélisation Ordinale

La distance entre les échelons de Likert (1 à 7) n'étant pas continue, la régression linéaire classique est biaisée. Nous avons implémenté un modèle logit ordinal estimant la probabilité cumulée :

$$P(Y \leq k) = \frac{1}{1 + e^{-(\alpha_k - (\beta_1 V + \beta_2 P))}}$$

Dans ce modèle, β s'interprète ainsi : pour une augmentation d'une unité de V , le log-odds de passer à une catégorie de croyance supérieure augmente de β (sous réserve que l'hypothèse des *proportional odds* soit vérifiée, ce qui n'a pas été formellement testé ici). Les intervalles de confiance ont été générés par **bootstrap par grappes (cluster bootstrap)**, en rééchantillonnant les 79 sujets entiers plutôt que les items individuels, afin de respecter la structure de dépendance intra-sujet.

B. Capacité de discrimination (AUC)

L'Aire Sous la Courbe ROC (AUC) a été obtenue via la statistique U du test de Mann-Whitney :

$$AUC = \frac{U}{n_1 n_0}$$

Où U est le nombre de paires (Vrai, Faux) pour lesquelles la croyance accordée à l’item vrai est strictement supérieure à celle de l’item faux, permettant d’interpréter l’AUC comme $P(C_{vrai} > C_{faux})$. Les intervalles de confiance ont été obtenus par rééchantillonnage bootstrap non apparié (tirages indépendants des groupes Vrai et Faux sur 2000 itérations).

C. Validation future (Kappa pondéré)

La validation future des annotations devra s’appuyer sur une mesure d’accord inter-juges au-delà du hasard, non calculée dans ce pilote. Pour deux annotateurs (ex : LLM vs Humain) sur des échelles ordinales, le Kappa de Cohen pondéré quadratique (Cohen, 1968) s’impose :

$$\kappa = \frac{p_o - p_e}{1 - p_e}$$

Pour un design impliquant plus de deux annotateurs humains, le Kappa de Fleiss sera privilégié.